

Floating Point (Kayan Noktalı Sayılar)

BIL-304: Bilgisayar Mimarisi

Dersi veren öğretim üyesi:

Dr. Öğr. Üyesi Fatih Gökçe

Ders kitabına ait sunum dosyalarından adapte edilmiştir: <http://csapp.cs.cmu.edu/>

Adapted from slides of the textbook: <http://csapp.cs.cmu.edu/>


Bu slayt setinde: Floating Point

- Arka plan: Kesirli ikili sayılar
- IEEE floating point standardı: Tanımlanması
- Örnekler ve özellikler

Kesirli ikili sayılar

■ 1011.101_2 kaçtır?

Kesirli ikili sayılar



■ Gösterim

- “İkili nokta” nın sağındaki bitler 2’nin kesirli kuvvetlerini ifade eder.
- İfade edilen kesirli sayının değeri:

$$\sum_{k=-j}^i b_k \times 2^k$$

Kesirli ikili sayılar: Örnekler

■ Değer	Gösterim
5 3/4	101.11 ₂
2 7/8	10.111 ₂
63/64	0.111111 ₂

■ Bulgular:

- Sağa (işaretsiz şekilde) kaydırarak 2'ye bölebiliriz
- Sola kaydırarak 2 ile çarpabiliriz.
- 0.111111...₂ biçimindeki sayılar 1.0'ın hemen altındadır.
 - $1/2 + 1/4 + 1/8 + \dots + 1/2^i + \dots \rightarrow 1.0$
 - Şu şekilde ifade edilir: $1.0 - \varepsilon$
 - ε : Sonsuz küçüklükte pozitif bir büyüklük.

İfade Edilebilen Sayılar

■ Limit #1

- Sadece $x/2^k$ biçimindeki sayıları kesin olarak ifade edebilir.
 - Diğer kesirli sayılar tekrar eden bitlerle ifade edilebilirler.
- Değer İfadesi
 - $1/3$ $0.0101010101[01]..._2$
 - $1/5$ $0.001100110011[0011]..._2$
 - $1/10$ $0.0001100110011[0011]..._2$

■ Limit #2

- w bit içinde sadece tek bir ondalık nokta yeri bulunur.
 - Limitli sayı aralığı (çok küçük değerler? çok büyük değerler?)

Bu slayt setinde: Floating Point

- Arka plan: Kesirli ikili sayılar
- IEEE floating point standardı: Tanımlanması
- Örnekler ve özellikler

IEEE Floating Point

■ IEEE Standart 754

- 1985 yılında kayan nokta aritmetiği için genel bir standart olarak oluşturulmuştur.
 - Öncesinde kendine özgü birçok format bulunuyordu.
- Tüm önemli CPUlar tarafından desteklendi.

■ Numerik çekincelerden oldukça etkilenmiştir

- Yuvarlama, taşma gibi durumlar için güzel bir standart getirmiştir.
- Yalnız, donanım olarak hızlı hale getirmek zordur.
 - Bunda, standart tanımlanırken nümerik analistlerinin donanım tasarımcılarına baskın çıkması etkili olmuştur.

Floating Point (Kayan Nokta) İfadesi

■ Nümerik Biçimi:

$$(-1)^s 2^E M$$

- İşaret biti **s** sayının negatif mi pozitif mi olduğunu belirler.
- Üst (Exponent) **E** sayının değerini 2'nin kuvvetiyle ağırlıklandırır.
- Anlamli kısım (Significand) **M** normalde [1.0,2.0) veya [0.0,1.0) aralığındaki bir ondalıklı değerdir.

■ Kodlama

- MSB (En anlamlı) s işaret bitidir: **s**
- exp alanı **E** 'yi kodlar. (Fakat exp, E'ye eşit değildir.)
- frac alanı **M** 'yi kodlar. (Fakat frac, M'ye eşit değildir.)



Hassasiyet seçenekleri


■ Tek hassasiyet: 32 bit float



■ Çift hassasiyet: 64 bit double



■ Genişletilmiş hassasiyet: 80 bit (Sadece Intel)



Float sayıların kategorileri


1. Denormalize



2. Normalize



3. a. Sonsuz



b. NaN (Not a Number, Bir sayı değil)



“Normalize” Değerler

- Bu değerlerde: $\text{exp} \neq 000\dots 0$ ve $\text{exp} \neq 111\dots 1$ 'dir.
- Üst (Exponent) *biased(yönlendirilmiş)* bir değer olarak kodlanmıştır: $E = \text{Exp} - \text{Bias}$
 - Exp : exp bitlerinin unsigned değeridir
 - $\text{Bias} = 2^{k-1} - 1$, k üst (exponent) bitlerinin sayısıdır.
 - Tek hassasiyette: 127 (Exp: 1...254, E: -126...127)
 - Çift hassasiyette: 1023 (Exp: 1...2046, E: -1022...1023)
- Anlamlı kısım (Significand) başında gizli bir 1 ile kodlanmıştır:

$$M = 1.\text{xxx}\dots\text{x}_2$$

- $\text{xxx}\dots\text{x}$: frac'taki bitler
- $\text{frac}=000\dots 0$ ($M = 1.0$) olduğunda en küçük değerdedir.
- $\text{frac}=111\dots 1$ ($M = 2.0 - \epsilon$) olduğunda en büyük değerdedir.
- Baştaki ekstra bit bedavadan gelir.

Normalize Kodlama Örneği

■ Değer: Float $F = 15213.0;$

$$\begin{aligned} 15213_{10} &= 11101101101101_2 \\ &= 2^{13} \times 1.1101101101101_2 \end{aligned}$$

■ Üst (Exponent)

$$\begin{aligned} E &= 13 \\ Bias &= 127 \\ Exp &= 140 = 10001100_2 \end{aligned}$$

■ Anlamli kısım (Significand)

$$\begin{aligned} M &= 1.\underline{1101101101101}_2 \\ frac &= \underline{1101101101101}0000000000_2 \end{aligned}$$

■ Sonuç:



Denormalize Değerler

- Şart: $\text{exp} = 000\dots 0$
- Üst (Exponent) değeri: $E = 1 - \text{Bias}$ ($E = 0 - \text{Bias}$ değildir.)
- Anlamli kısım (Significand) başında gizli bir 0 ile kodlanmıştır :

$$M = 0.\text{xxx}\dots\text{x}_2$$

- $\text{xxx}\dots\text{x}$: frac 'taki bitler
- Durumlar
 - $\text{exp} = 000\dots 0$, $\text{frac} = 000\dots 0$
 - Sıfır değerini ifade eder
 - Sıfıra dikkat: $+0$ ve -0 bulunur (niçin?)
 - $\text{exp} = 000\dots 0$, $\text{frac} \neq 000\dots 0$
 - 0.0 'a en yakın sayılardır.
 - Eşit aralıklarla birbirlerinden ayrılmışlardır.


Özel Değerler

- **Şart: $\text{exp} = 111\dots 1$**
- **Durum: $\text{exp} = 111\dots 1, \text{frac} = 000\dots 0$**
 - ∞ (sonsuz, infinity) değerini ifade eder.
 - Taşma olan işlemlerde
 - Hem pozitif hem de negatif
 - E.g., $1.0/0.0 = -1.0/-0.0 = +\infty$, $1.0/-0.0 = -\infty$
- **Durum: $\text{exp} = 111\dots 1, \text{frac} \neq 000\dots 0$**
 - Not-a-Number (NaN), Sayı değil
 - Herhangi bir nümerik değer belirlenemiyorsa bu durumu ifade eder.
 - Örnek, $\sqrt{-1}$, $\infty - \infty$, $\infty \times 0$

Özel değerlerle ilgili kurallar

İşlem	Sonuç
$n / \pm\infty$	± 0
$\pm\infty \times \pm\infty$	$\pm\infty$
sıfırdan_farklı_bir_değer / 0	$\pm\infty$
$\infty + \infty$	∞ ($-\infty$ için de benzer)
$\pm 0 / \pm 0$	NaN
$\infty - \infty$	NaN ($-\infty$ için de benzer)
$\pm\infty / \pm\infty$	NaN
$\pm\infty \times \pm 0$	NaN
NaN operatör herhangi_birşey	NaN


Görselleştirme: Floating Point Kodlamalar



Bu slayt setinde: Floating Point

- Arka plan: Kesirli ikili sayılar
- IEEE floating point standardı: Tanımlanması
- Örnekler ve özellikler

Küçük Floating Point Örneği



■ 8-bit Floating Point ifadesi

- İşaret biti en anlamlı bittir.
- Sonraki 4 bit üst (exponent)'tür. 4 bit için bias 7 yapar.
- En sondaki 3 bit: **frac**

■ IEEE Formatıyla aynı genel format

- normalize, denormalize
- 0'ın ifadesi, NaN, sonsuz.


Dinamik Aralık (Sadece Pozitif kısım)

	s	exp	frac	E	Değer	
Denormalize sayılar	0	0000	000	-6	0	
	0	0000	001	-6	$1/8 * 1/64 = 1/512$	Sıfıra en yakın
	0	0000	010	-6	$2/8 * 1/64 = 2/512$	
	...					
	0	0000	110	-6	$6/8 * 1/64 = 6/512$	
	0	0000	111	-6	$7/8 * 1/64 = 7/512$	En büyük denormalize
Normalize sayılar	0	0001	000	-6	$8/8 * 1/64 = 8/512$	En küçük normalize
	0	0001	001	-6	$9/8 * 1/64 = 9/512$	
	...					
	0	0110	110	-1	$14/8 * 1/2 = 14/16$	
	0	0110	111	-1	$15/8 * 1/2 = 15/16$	1'in aşağısında 1'e en yakın
	0	0111	000	0	$8/8 * 1 = 1$	
	0	0111	001	0	$9/8 * 1 = 9/8$	1'in yukarısında 1'e en yakın
	0	0111	010	0	$10/8 * 1 = 10/8$	
	...					
	0	1110	110	7	$14/8 * 128 = 224$	
	0	1110	111	7	$15/8 * 128 = 240$	En büyük normalize
	0	1111	000	n/a	sonsuz (infinity)	


Değerlerin Dağılımı

■ 6-bit IEEE-benzeri format

- $e = 3$ exponent biti
- $f = 2$ fraction biti
- Bias: $2^{3-1}-1 = 3$





■ Dağılımın sıfıra doğru nasıl yoğunlaştığına dikkat ediniz.



Değerlerin Dağılımı (yakından bakış)

■ 6-bit IEEE-benzeri format

- $e = 3$ exponent biti
- $f = 2$ fraction biti
- Bias = 3



Kodlamanın özel özellikleri

■ Floating Point sıfır, Integer sıfırla aynıdır.

- Tüm bitler = 0 (-0'da sadece işaret biti 1 diğerleri 0'dır.)

■ Unsigned Integer karşılaştırması hemen hemen geçerlidir.

- Önce işaret bitleri karşılaştırılmalıdır
- $-0 = 0$ eşitliği göz önünde bulundurulmalıdır.
- NaN'lar problemlidir:
 - Diğer değerlerden büyük olacaktırlar.
 - float a,b;
 - a ve b NaN değer aldı
 - if(a == b) ve if(a != b) ne döner?
- Bunun dışında OK
 - Denormalize sayılarla normalize sayıların karşılaştırılması
 - Normalize sayılarla sonsuz(infinity)'un karşılaştırılması