

SÜLEYMAN DEMİREL ÜNİVERSİTESİ




BİL-311 – VERİ MADENCİLİĞİ

Doç. Dr. Utku KÖSE

1. Hafta – Veri Madenciliğine Giriş

Veritabanı teknolojisinin gelişimi




Neden veri madenciliği?

- Bilgisayarların ucuzlayıp aynı zamanda çok güçlü hale gelmeleri
- Teknolojinin gelişimiyle bilgisayar ortamında ve veritabanlarında tutulan veri miktarının da artması (terabyte to petabyte)
- Yeni veri toplama yolları
 - Otomatik veri toplama aletleri, veritabanı sistemleri, bilgisayar kullanımının artması
- Büyük veri kaynakları
 - İş dünyası: Web, e-ticaret, alışveriş, hisse senetleri, ...
 - Bilim dünyası: Uzaktan algılama ve izleme, bioinformatik, simülasyonlar..
 - Toplum: haberler, digital kameralar, YouTube, Facebook...
- Ticari rekabet baskısının artması
 - Kişiselleştirilmiş ürünler, CSR yönetimi
- **Veri içinde boğuluyoruz, ancak bilgi elde edemiyoruz!!!**



Neden veri madenciliği?



Veri Madenciliğinin Amacı

- Ne yapmak istemiyoruz?
 - Büyük miktardaki veri içinde arama yapmak (Veritabanı yönetim sistemleri bu işi yapıyor)
 - Telefon rehberinde arama yapmak
- Veri madenciliğinin amacı:
 - Aradığımız veri mevcutsa bu veriden çıkarabileceğimiz sonuçlarını anlamak
 - Telefon rehberindeki isimlere göre, hangi bölgemizde hangi isimlerin daha yaygın olduğunu bulmak

Veritabanı - Veri Madenciliği Karşılaştırması

- Sorgulama
 - Tanımlı
 - SQL
- Veri
 - Canlı veri
 - Dinamik
- Çıktı
 - Belirli
 - Verinin bir alt kümesi

Veritabanı

- Sorgulama
 - Tam tanımlı değil
 - Yaygın sorgulama dili yok
- Veri
 - Üzerinde işlem yapılmayan veri
 - Statik
- Çıktı
 - Belirli değil
 - Verinin bir alt kümesi değil

Veri Madenciliği

Sorgulama örnekleri


- Veritabanı uygulaması:
 - Adı Ahmet olan kredi kartı sahiplerini bul.
 - Bir ayda 2000 YTL'den fazla harcama yapan kredi kartı sahiplerini bul.
 - DVD satın alan tüm müşterileri bul.
- Veri madenciliği uygulaması
 - Riski az olan tüm kredi kartı başvurularını bul (sınıflandırma)
 - Harcama alışkanlığı benzer olan kredi kartı sahiplerini bul (demetleme)
 - DVD birlikte sıkça satın alınan ürünü bul (ilişkilendirme kuralları)

Veri madenciliği nedir?

- Veri madenciliği
 - Basit ve açık olmayan, önceden bilinmeyen ve yararlı olan örüntülerin ya da bilginin çok büyük miktarlardaki veriden çıkarılması
 - Sorgulama ya da basit istatistik yöntemler veri madenciliği değildir.
 - Veri madenciliği terimi ne kadar doğru?
- **KNOWLEDGE DISCOVERY FROM DATA (KDD) (VERİDEN BİLGİ KEŞFİ)**
- Alternatif isimler
 - Knowledge discovery (mining) in databases (KDD), knowledge extraction, data/pattern analysis, data archeology, data dredging, information harvesting, business intelligence, etc.

Veriden Bilgi Keşfi

Teoride veri madenciliği bilgi keşfi işleminin bir parçasıdır
Pratikte veri madenciliği ve veriden bilgi keşfi aynı anlamda kullanılır



Veriden Bilgi Keşfinin Aşamaları

- Uygulama alanını inceleme
 - Konuyla ilgili bilgi ve uygulama amaçları
- Veri toplama ve birleştirme
- Amaca uygun veri kümesi oluşturma: Veri seçme
- Veri ayıklama ve ön işleme
- Veri azaltma ve veri dönüşümü
 - incelemede gerekli boyutları (özellikleri) seçme, boyutlar arası ilişkiyi belirleme, boyut azaltma,
- Veri madenciliği tekniği seçme
 - Sınıflandırma, eğri uydurma, bağıntı kuralları, demetleme
- Veri madenciliği algoritmasını seçme
- Model değerlendirme ve bilgi sunumu
- Bulunan bilginin yorumlanması

Örnek: WEB madenciliği

- web sitesinin yapısını inceleme
- veri toplanması: log dosyaları, üye veri tabanı ve satış kayıtlarının toplanması
- verileri seçme: tarih aralığını belirleme
- veri ayıklama, önişleme: gereksiz kayıtları silme
- veri azaltma, veri dönüşümü: kullanıcı oturumları belirleme
- veri madenciliği tekniği seçme: demetleme
- veri madenciliği algoritması seçme: k-ortalama, EM, DBSCAN...
- Model değerlendirme/yorumlama: değişik kullanıcı grupları için sıkça izlenen yolu bulma
- Uygulama alanları: öneri modelleri, kişiselleştirme, ön belleğe alma



Kaynaklar

- Prof. Dr. Suat Özdemir Ders Notları:
<http://ceng.gazi.edu.tr/~ozdemir/teaching/dm>

SÜLEYMAN DEMİREL ÜNİVERSİTESİ



TEŞEKKÜRLER