

SÜLEYMAN DEMİREL ÜNİVERSİTESİ



BİL-311 – VERİ MADENCİLİĞİ

Doç. Dr. Utku KÖSE

6. Hafta – kMeans Kümeleme Algoritması

K-Ortalamalar Yöntemi (K-Means) (1/2)

- Bu yöntemde daha başlangıçta belli sayıdaki küme için toplam ortalama hatayı minimize etmek amaçlanır.
- N boyutlu uzayda N örnekli kümelerin verildiğini varsayalım. Bu uzay $\{C_1, C_2, \dots, C_k\}$ biçimde K kümeye ayrılsın. O zaman $\sum n_k = N$ ($k=1, 2, \dots, k$) olmak üzere C_k kümesinin ortalama vektörü M_k şu şekilde hesaplanır.

$$M_k = \frac{1}{n_k} \sum_{i=1}^{n_k} X_{ik}$$

- Burada X_k değeri C_k kümesine ait olan i . örnektir. C_k kümesi için kare-hata, her bir C_k örneği ile onun merkezi (centroid) arasındaki Öklid uzaklıkları toplamıdır. Bu hataya «küme içi değişme» adı da verilir.

K-Ortalamalar Yöntemi (K-Means)

(2/2)

- Küme içi değişimler şu şekilde hesaplanır.

$$e_i^2 = \sum_{i=1}^{n_k} (X_{ik} - M_k)^2$$

- K kümesini içeren bütün kümeler uzayı için kare-hata içindeki değişimlerin toplamıdır. O halde söz konusu kare-hata şu şekilde hesaplanır.

$$E_k^2 = \sum_{k=1}^K e_k^2$$

- Kare-hata kümeleme yönteminin amacı verilen K değeri için E_k^2 değerini minimize eden K kümelerini bulmaktır. O halde k-ortalamlar algoritmasında E_k^2 değerinin bir önceki iterasyona göre azalması beklenir.

K-Means Algoritmasının Adımları

- K-Means algoritmasına başlamadan önce k küme sayısının belirlenmesi gerekir. Sonra aşağıdaki işlemler gerçekleştirilir.
- 1. Her bir kümenin merkezi belirlenir. Bu merkezler $M_1, M_2, \dots, M_k$ biçimindedir.
- 2. $e_1, e_2, \dots, e_k$ küme içi değişmeler hesaplanır. Bu değişmelerin toplamı olan E_k^2 değeri bulunur.
- 3. M_k merkez değerleri ile gözlem değerleri arasındaki uzaklıklar hesaplanır. Bir gözlem değeri hangi yakın ise o merkez ile ilgili küme içine dahil edilir.
- 4. Yukarıdaki 2. ve 3. adımlar kümelerde değişiklik olmayıncaya kadar devam ettirilir.

K-Means Algoritmasının Özellikleri

- Gerçeklemesi kolay
- Karmaşıklığı diğer kümeleme yöntemlerine göre az
- K-Means algoritması bazı durumlarda iyi sonuç vermeyebilir
 - Veri grupları farklı boyutlarda ise
 - Veri gruplarının yoğunlukları farklı ise
 - Veri gruplarının şekli küresel değilse
 - Veri içinde aykırılıklar varsa

Örnek 2.

- Aşağıdaki gözlem değerleri k-ortalamlar yöntemi ile kümelenmek isteniyor.

Gözlemler	Değişken1	Değişken2
X_1	4	2
X_2	6	4
X_3	5	1
X_4	10	6
X_5	11	8

- Kümelerin sayısı başlangıçta $k=2$ kabul edilir. Rasgele iki küme belirlenir.

$$C_1 = \{X_1, X_2, X_4\}$$

$$C_2 = \{X_3, X_5\}$$

Örnek 2.

Gözlemler	Değişken1	Değişken2	Küme Üyeliği
X ₁	4	2	C ₁
X ₂	6	4	C ₁
X ₃	5	1	C ₂
X ₄	10	6	C ₁
X ₅	11	8	C ₂

- Adım 1. a) Belirtilen iki kümenin merkezleri şu şekilde hesaplanır.

$$M_1 = \left\{ \frac{4 + 6 + 10}{3}, \frac{2 + 4 + 6}{3} \right\} = \{6.67, 4.0\}$$

$$M_2 = \left\{ \frac{5 + 11}{2}, \frac{1 + 8}{2} \right\} = \{8.0, 4.5\}$$

Örnek 2.

- b) Küme içi değişmeler şu şekilde hesaplanır.

$$e_1^2 = [(4 - 6,67)^2 + (2 - 4,0)^2] + [(6 - 6,67)^2 + (4 - 4,0)^2] + [(10 - 6,67)^2 + (6 - 4,0)^2] = 26,67$$

$$e_2^2 = [(5 - 8)^2 + (1 - 4,5)^2] + [(11 - 8)^2 + (8 - 4,5)^2] = 42,50$$

- Bu durumda toplam kare-hata şu şekilde hesaplanır.

$$E^2 = e_1^2 + e_2^2 = 26,67 + 42,50 = 69,17$$

Örnek 2.

- C) M_1 ve M_2 merkezlerinden olan uzaklıkların minimum olması istendiğinden aşağıdaki hesaplamalar yapılır. Öklid uzaklık formülü kullanılarak söz konusu mesafeler hesaplanır. Örneğin (M_1, X_1) noktaları arasındaki uzaklık $M_1 = \{6.67, 4.00\}$ ve $X_1 = \{4, 2\}$ olduğuna göre şu şekilde hesaplanır.

$$d(M_1, X_1) = \sqrt{(6.67 - 4)^2 + (4 - 2)^2} = 3.33$$

$$d(M_2, X_1) = \sqrt{(8 - 4)^2 + (4.5 - 2)^2} = 4.72$$

- Bu işlemler sonucunda X_1 gözlem değerinin M_1 ve M_2 merkezlerine olan uzaklıkları göz önüne alındığında $d(M_1, X_1) < d(M_2, X_1)$ olduğu görülür. Bu durumda M_1 merkezinin X_1 gözlem değerine daha yakın olduğu anlaşılır. O halde $X_1 \in C_1$ olarak kabul edilir. Benzer biçimde tüm gözlem değerleri için tablo oluşturulur.

Örnek 2.

Gözlemler	M_1 'den uzaklık	M_2 'den uzaklık	Küme Üyeliği
X_1	$d(M_1, X_1) = 3,33$	$d(M_2, X_1) = 4,72$	C_1
X_2	$d(M_1, X_2) = 0,67$	$d(M_2, X_2) = 2,06$	C_1
X_3	$d(M_1, X_3) = 3,43$	$d(M_2, X_3) = 4,61$	C_1
X_4	$d(M_1, X_4) = 3,89$	$d(M_2, X_4) = 2,50$	C_2
X_5	$d(M_1, X_4) = 5,90$	$d(M_2, X_4) = 4,61$	C_2

Örnek 2.

- Bu durumda yeni kümeler şu şekilde olacaktır.

$$C_1 = \{X_1, X_2, X_3\}$$

$$C_2 = \{X_4, X_5\}$$

- Adım 2. Yukarıda belirtilen iki kümenin merkezleri şu şekilde hesaplanır.

$$M_1 = \left\{ \frac{4 + 6 + 5}{3}, \frac{2 + 4 + 1}{3} \right\} = \{5, 2.33\}$$

$$M_2 = \left\{ \frac{10 + 11}{2}, \frac{6 + 8}{2} \right\} = \{10.5, 7\}$$

Örnek 2.

- b) Küme içi değişmeler şu şekilde hesaplanır.

$$e_1^2 = [(4 - 5)^2 + (2 - 2,33)^2] + [(6 - 5)^2 + (4 - 2,33)^2] + [(5 - 5)^2 + (1 - 2,33)^2] = 9,33$$

$$e_2^2 = [(10 - 10,5)^2 + (6 - 7)^2] + [(11 - 10,5)^2 + (8 - 7)^2] = 2,50$$

- Bu durumda toplam kare-hata şu şekilde hesaplanır.

$$E^2 = e_1^2 + e_2^2 = 9,33 + 2,50 = 11,83$$

- Bu değer bir önceki iterasyonda elde edilen $E^2 = 69,17$ değerinden daha küçük olduğu anlaşılmaktadır.

Örnek 2.

- M_1 ve M_2 merkezlerinden gözlem değerlerine olan uzaklıklar hesaplanır. Bunun sonucunda $d(M_1, X_1) < d(M_2, X_1)$ olduğu görülür. Bu durumda M_1 merkezinin X_1 gözlem değerine daha yakın olduğu anlaşılır. O halde $X_1 \in C_1$ olarak kabul edilir. Benzer biçimde tüm gözlem değerleri için tablo oluşturulur.

Gözlemler	M_1 'den uzaklık	M_2 'den uzaklık	Küme Üyeliği
X_1	$d(M_1, X_1) = 1,05$	$d(M_2, X_1) = 8,20$	C_1
X_2	$d(M_1, X_2) = 1,94$	$d(M_2, X_2) = 5,41$	C_1
X_3	$d(M_1, X_3) = 1,33$	$d(M_2, X_3) = 8,14$	C_1
X_4	$d(M_1, X_4) = 6,20$	$d(M_2, X_4) = 1,12$	C_2
X_5	$d(M_1, X_4) = 8,25$	$d(M_2, X_4) = 1,12$	C_2

Örnek 2.

- Bu durumda yeni kümeler şu şekilde oluşacaktır.

$$C_1 = \{X_1, X_2, X_3\}$$

$$C_2 = \{X_4, X_5\}$$

- Kümelerde önceki adıma göre herhangi bir değişme olmadığı için iterasyona son verilir.



Kaynaklar

- Dr. Kadriye Ergün Ders Notları:

<https://docplayer.biz.tr/58092378-Veri-madenciligi-kumeleme-yrd-doc-dr-kadriye-ergun.html>

SÜLEYMAN DEMİREL ÜNİVERSİTESİ



TEŞEKKÜRLER