

SÜLEYMAN DEMİREL ÜNİVERSİTESİ



BİL-311 – VERİ MADENCİLİĞİ

Doç. Dr. Utku KÖSE

7. Hafta – Karar Ağaçları

Tarihçesi

- Morgan ve Sonquist tarafından Michigan Üniversitesi'nde 1970'li yılların başlarında kullanılan AID (Automatic Detector) karar ağacı ilk algoritma ve yazılımıdır.
- Bu yöntem 60 yılı aşkın süredir kullanımdadır.




Karar Ağacı Nedir ?

- ▶ Karar ağacı ağaç yapısı şeklinde sınıflandırıcı algoritmasıdır.
- ▶ Karar Ağaçları tümevarımlı mantığın programlama ortamına taşındığı basit fakat çok yaygın bir metoddur.
- ▶ Ayrik değerli parametrelerle çalışır.Gürültüye karşı dayanıklı bir algoritmadır.
- ▶ C4.5 karar ağacı algoritması ailesi içinde en popüler algoritmadır.
- ▶ Karar ağacı algortimalarının dayandığı tüme varımlı felsefeye dair temel sezgi öğrenme özellikleriyle oluşturulacak karar ağacının olabidiğince küçük olmasının iyi olcağı yönündedir.


Karar Ağacı Elemanları

- ▶ İç Karar Düğümleri: Giriş verilerinin test edildiği, soruların sorulduğu ve hangi yöne yöneleceklerini belirleyen karar düğümleri
- ▶ Dal: Bu soruların cevaplarını temsil eder
- ▶ Uç Yapraklar: Kategorin bulunduğu sınıf etiketleri .



(2) Hangi Düğümde Devam Edeceksin?


(3) Ne zaman Duracaksın/ Sonuca Ulaşacaksın?



Rastgele oluşturulmuş karar ağacı örneği


Özellikler

- ▶ Eğitici öğrenme (Supervised learning) algoritması
- ▶ Kullanımı yaygın
 - ▶ ürettikleri kuralların kolay anlaşılır olması
 - ▶ kolay uygulanabilir olmaları
 - ▶ hem kategorik hem de sayısal verileri işleyebilirler



Algortimanın Adımları

- 1-Her öznitelik üzerinde bölme için bilgi kazancını hesapla(entropy(variance) azalma).
- 2-Yeni bir düğüm için en fazla bilgi kazancını veren öz niteliği seç.
- 3-Bu öz niteliğe dayalı olması eğitim verisini böl.
- 4-Alt düğümlere kadar hepsi için (Adım 1=>3) özyinelemeli olarak işlemi yineleyin.



Karar Ağaçlarında Karar Düğümlerini Oluşturacak Ey İyi Nitelik Neden Seçilir?

- ▶ Kök düğümde ağacın dengeli bir şekilde dallanması ve sınıflandırma algoritmasının verimli olması için özellikler içinden en uygun olanı seçilir.
- ▶ Kök düğüm için uygulanan algoritma iç karar düğümleri içinde söz konusudur.

Karar Ağaçlarında Karar Düğümlerini Oluşturacak En İyi Nitelik Nasıl Seçilir?

Shannon ve Weaver tarafından ilk defa tanımlanan **Enformasyon Teorisi** ile bütün sistemdeki beklenen değeri hesaplayabiliyoruz.



Claude Elwood Shannon



Warren Weaver

Entropi

- ▶ $p_1, p_2, \dots, p_m$ toplamaları 1 olan olasılıklar.
- ▶ örnekler aynı sınıfa aitse entropi=0
- ▶ örnekler sınıflar arasında eşit dağılmışsa entropi=1
- ▶ örnekler sınıflar arasında rastgele dağılmışsa $0 < \text{entropi} < 1$

Entropi formülü

$$E(S) = - p(P)\log_2 p(P) - p(N)\log_2 p(N)$$

Information Gain(Bilgi Kazancı)

- ▶ Bilgi kazancı entropide ki beklenen azalmayı ölçer.
- ▶ Bu şekilde bizim için uygun olan özellik seçimini gerçekleştirebiliyoruz.

Bilgi Kazancı=Sistemin Enformasyon Değeri – Özelliğin Enformasyon Değeri

Örnek:

V1	V2	S
A	C	E
B	C	F
B	D	E
B	D	F

Sınıf Entropisi

$$H(S) = -\left(\frac{1}{2}\log_2 \frac{1}{2} + \frac{1}{2}\log_2 \frac{1}{2}\right) = 1$$

V1 Entropisi

$$\begin{aligned} H(V1) &= \frac{1}{4}H(A) + \frac{3}{4}H(B) \\ &= \frac{1}{4}0 - \frac{3}{4}\left(\frac{1}{3}\log_2 \frac{1}{3} + \frac{2}{3}\log_2 \frac{2}{3}\right) \\ &= 0 + \frac{3}{4}0,9183 = 0,6887 \end{aligned}$$

V2 Entropisi

$$H(V2) = \frac{1}{2}H(C) + \frac{1}{2}H(D) = \frac{1}{2} + \frac{1}{2} = 1$$

$$H(S) - H(V1) \Rightarrow 1 - 0,6887 = 0,3113$$

$$H(S) - H(V2) \Rightarrow 1 - 1 = 0$$

✓ **V1 Seçilir.**


Karar Ağaçları: Haftasonu Örneği

- 1. Adım: Veri setinden öğrenme kümesi oluşturulur.

Weekend (Example)	Weather	Parents	Money	Decision (Category)
W1	Sunny	Yes	Rich	Cinema
W2	Sunny	No	Rich	Tennis
W3	Windy	Yes	Rich	Cinema
W4	Rainy	Yes	Poor	Cinema
W5	Rainy	No	Rich	Stay in
W6	Rainy	Yes	Poor	Cinema
W7	Windy	No	Poor	Cinema
W8	Windy	No	Rich	Shopping
W9	Windy	Yes	Rich	Cinema
W10	Sunny	No	Rich	Tennis

Karar Ağaçları: Haftasonu örneği

- 2. Adım: Veri setindeki en ayırt edici nitelik belirlenir ve ağacın kökü olarak alınır.



- 3. Adım: Ağacın çocuk düğümü olan A düğümüne ait alt veri kümesi belirlenir.

Weekend (Example)	Weather	Parents	Money	Decision (Category)
W1	Sunny	Yes	Rich	Cinema
W2	Sunny	No	Rich	Tennis
W10	Sunny	No	Rich	Tennis

Haftasonu Örneği: Entropy

- ▶ Haftasonu veri kümesindeki 10 örnekten
 - ▶ 6 örnek için karar sinema
 - ▶ 2 örnek için karar tenis oynamak
 - ▶ 1 örnek için karar evde kalmak ve
 - ▶ 1 örnek için karar alışverişe gitmek olduğuna göre
- ▶ Entropy: $H(T) = - (6/10) \log_2(6/10) - (2/10) \log_2(2/10) - (1/10) \log_2(1/10) - (1/10) \log_2(1/10)$
 $H(S) = 1,571$

Haftasonu Örneği :Bilgi Kazancı

- ▶ Gain(weather)= ?
 - ▶ Sunny=3 (1 Cinema, 2 Tennis)
 - ▶ Windy=4 (3 Cinema, 1 Shopping)
 - ▶ Rainy=3 (2 Cinema, 1 Stay in)
 - ▶ Entropy(T_{sunny})= $-(1/3) \log_2 (1/3) - (2/3) \log_2 (2/3) = 0,918$
 - ▶ Entropy(T_{windy})= $-(3/4) \log_2 (3/4) - (1/4) \log_2 (1/4) = 0,811$
 - ▶ Entropy(T_{rainy})= $-(2/3) \log_2 (2/3) - (1/3) \log_2 (1/3) = 0,918$
- ▶ Gain(weather) = Entropy(T)- ((P(sunny)Entropy(T_{sunny}) +
P(windy) Entropy(T_{windy})+ P(rainy) Entropy(T_{rainy}))
=1,571- ((3/10)Entropy(T_{sunny})+(4/10)Entropy(T_{windy})+ (3/10)Entropy(T_{rainy}))
Gain(T, weather) =0,70

Haftasonu Örneği :Bilgi Kazancı

- ▶ $\text{Gain}(T, \text{parents}) = ?$
 - ▶ Yes=5 (5 Cinema)
 - ▶ No =5 (2 Tennis, 1 Cinema, 1 Shopping, 1 Stay in)
 - ▶ $\text{Entropy}(T_{\text{yes}}) = - (5/5) \log_2 (5/5) = 0$
 - ▶ $\text{Entropy}(T_{\text{no}}) = - (2/5) \log_2 (2/5) - 3(1/5) \log_2 (1/5) = 1,922$
- ▶ $\text{Gain}(T, \text{parents}) = \text{Entropy}(T) - ((P(\text{yes})\text{Entropy}(T_{\text{yes}}) + P(\text{no}) \text{Entropy}(T_{\text{no}}))$
 $= 1,571 - ((5/10)\text{Entropy}(T_{\text{yes}}) + (5/10)\text{Entropy}(T_{\text{no}}))$
 $\text{Gain}(T, \text{parents}) = 0,61$


Haftasonu Örneği :Bilgi Kazancı

- ▶ $\text{Gain}(T, \text{money}) = ?$
 - ▶ Rich=7 (3 Cinema, 2 Tennis, 1 Shopping, 1 Stay in)
 - ▶ Poor=3 (3 Cinema)
 - ▶ $\text{Entropy}(T_{\text{rich}}) = 1,842$
 - ▶ $\text{Entropy}(T_{\text{poor}}) = 0$
- ▶ $\text{Gain}(T, \text{money}) = \text{Entropy}(T) - ((P(\text{rich})\text{Entropy}(T_{\text{rich}}) + P(\text{poor}) \text{Entropy}(T_{\text{poor}}))$
 $= 1,571 - ((5/10)\text{Entropy}(T_{\text{rich}}) + (5/10)\text{Entropy}(T_{\text{poor}}))$

$\text{Gain}(T, \text{money}) = 0,2816$

Haftasonu Örneği :Bilgi Kazancı

- ▶ $\text{Gain}(T, \text{weather}) = 0,70$
- ▶ $\text{Gain}(T, \text{parents}) = 0,61$
- ▶ $\text{Gain}(T, \text{money}) = 0,2816$
- ▶ Weather özelliği en büyük bilgi kazancını sağladığı için ağacın kökünde yer alacak özellik olarak seçilir. Bu özellik en ayırt edici özellik olarak bulunmuş olur.



Haftasonu Örneği

- 3. Adım: Ağacın çocuk düğümü olan A düğümüne ait alt veri kümesi belirlenir.

Weekend (Example)	Weather	Parents	Money	Decision (Category)
W1	Sunny	Yes	Rich	Cinema
W2	Sunny	No	Rich	Tennis
W10	Sunny	No	Rich	Tennis


- Her alt küme için tekrar bilgi kazancı hesaplanarak en ayırt edici özellik belirlenir.

$$\begin{aligned}\text{Gain}(S_{\text{sunny, parents}}) &= 0.918 - (|S_{\text{yes}}|/|S|) * \text{Entropy}(S_{\text{yes}}) - (|S_{\text{no}}|/|S|) * \text{Entropy}(S_{\text{no}}) \\ &= 0.918 - (1/3) * 0 - (2/3) * 0 = 0.918\end{aligned}$$

$$\begin{aligned}\text{Gain}(S_{\text{sunny, money}}) &= 0.918 - (|S_{\text{rich}}|/|S|) * \text{Entropy}(S_{\text{rich}}) - (|S_{\text{poor}}|/|S|) * \text{Entropy}(S_{\text{poor}}) \\ &= 0.918 - (3/3) * 0.918 - (0/3) * 0 = 0.918 - 0.918 = 0\end{aligned}$$

Haftasonu Örneđi

- Yeni düğüm için en ayırt edici özellik **Parents** olarak belirlenmiştir. Bu işlemler her düğüm için aşağıdaki durumlardan biri oluşuncaya kadar devam eder
 - Örneklerin hepsi aynı sınıfa ait
 - Örnekleri bölecek özellik kalmamış
 - Kalan özelliklerin değerini taşıyan örnek yok





Kaynaklar

- Reyhan Koç Ders Notu:

<https://www.slideshare.net/reyhanko/karar-aalari-63285758>

SÜLEYMAN DEMİREL ÜNİVERSİTESİ



TEŞEKKÜRLER