

SÜLEYMAN DEMİREL ÜNİVERSİTESİ



BİL-311 – VERİ MADENCİLİĞİ

Doç. Dr. Utku KÖSE

11. Hafta – Destek Vektör Makineleri

SVM sınıflandırma

- Son derslerde, karmaşık ve zor ama çok güçlü makine öğrenme yaklaşımı öğrendik – Yapay Sınır Ağları
- SVM, **linear sınıflandırma** makine öğrenme metodudur
- Son derecede basit; aynı zamanda gerçek uygulamalarda Yapay Sınır Ağlarının yakın derecesinde güçlü yöntemdir

SVM sınıflandırma

- “Sınıflandırma” hatırlatılması
 - Modellenecek ilişki/değişken sadece **ayrık değerlerde** bulunabilir
 - Çoğunlukla, sadece iki değeri var – *evet/hair, pozitif/negatif, başarılı/başarısız, oldu/olmadı, vb*
 - Önceden var olan örneklerle göre, yeni durumunun belirli bir **sınıfta olmasını** belirlemek lazım (*sınıflandırma sorunu*)

SVM sınıflandırma

- Sınıflandırma makine öğrenme en derecede önemli çünkü tipik makine öğrenme sorunları yada karar verme sorunları “sınıflandırma” şeklindedir;

SVM sınıflandırma

- Spam mesajları yakalamak
- Erken olarak hastaları bulmak
- Aday işine uygunluğu belirlemek
- Konuşmadaki sözün var olduğunu belirtmek
- Resimdeki belirli türden nesne bulmak
- Haber mesajının belirli insan için ilginç olabilmesi belirlemek

SVM sınıflandırma

Sınıflandırma sorunu


- Durumu iki yada az sınıfa koymak lazım (sınıflandırma)
- Çıktı sınıf etiketi – ayrık değerleri
- *Test sonuçlarına göre ciddi hastalık olup olmadığını söylemek*

Regresyon sorunu

- Duruma göre sürekli değerli sonucu tahmin etmek lazım (regresyon)
- Çıktı sonuç değeri – sürekli değerleri
- *Ev özelliklerine göre satılabilecek fiyatını tahmin etmek*

SVM sınıflandırma

- “Tüm karşı bir” birkaç sınıflı sınıflandırma;



Birkaç-
olasılıklı soru

“A mı?” iki-
olasılıklı soru

“B mı?” iki-
olasılıklı soru

SVM sınıflandırma

- Notasyon

- x 'ler – özellikler (bir özellik vektörü veya dizisi)
- y 'ler – sonuçlar (sınıf etiketleri, evet/hair, 1/0, vb)
- n – özelliklerin sayısı (x 'in boyutu)
- x_j – j . özellik
- (x^i, y^i) – bir örnek, önceden var olan özellikler için sonuç
- m –örneklerin sayısı
- bütün (x^i, y^i) –“eğitim kümesi”

SVM sınıflandırma


SVM – “Support Vector Machine” yada “Destek Vektör Makinesi”, önce görülen lojistik regresyona benzer bir **lineer sınıflandırma metodudur**;

- “pozitif” ($y=+1$) ve “negatif” ($y=-1$) örnekler için, bu örnekleri doğru şekilde bölen **lineer karar sınırı** buluyor

SVM sınıflandırma

Karar sınırı:

Positif örnekler: $y=1$



Negatif örnekler: $y=-1$

SVM sınıflandırma

Lojistik regresyon böyle sınırı bulmak için, özel maliyet fonksiyonunu azaltılma sorunu formülleştirdi:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (-y^i \log h_{\theta}(x^i) - (1 - y^i) \log(1 - h_{\theta}(x^i)))$$

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T \cdot x}}$$

model

$$y^i = \{0,1\}$$

gereken çıktılar



SVM sınıflandırma

SVM, bu sınırı farklı açıdan buluyor ...

SVM sınıflandırma


“Büyük Kenar Prensibi”

- Büyük Kenar Prensibine göre, karar sınırı bu şekilde olmalı ki, pozitif ve negatif örneklerin arasında en büyük kenarı kalır

SVM sınıflandırma

Karar kenarı:

Positif örnekler: $y=1$



Kenar


Pozitif ve
negatif
örneklerin
arasındaki
mesafe

Negatif örnekler: $y=-1$

SVM sınıflandırma

En büyük karar kenarı?

Positif örnekler: $y=1$




Kenar

Negatif örnekler: $y=-1$

SVM sınıflandırma

En büyük karar kenarı?

Positif örnekler: $y=1$




Kenar

Negatif örnekler: $y=-1$

SVM sınıflandırma

En büyük karar kenarı !

Positif örnekler: $y=1$



En büyük kenar

Negatif örnekler: $y=-1$

SVM sınıflandırma


“Büyük Kenar Prensibi”

- En büyük kenarı, **en gürbüz kararlar** demektir !
- Örneklerde gürültü varsa, en büyük kenarıyla en gürbüz karar verme yapılabilir

SVM sınıflandırma

Az kenarlı karar sınırı, gürültü tarafından kolayca etkilenebilir

Positif örnekler: $y=1$




Negatif örnekler: $y=-1$

SVM sınıflandırma

Büyük kenarlı karar sınırı, en gürbüz karar verme demektir !

Positif örnekler: $y=1$



Negatif örnekler: $y=-1$

HATA YOK !

SVM sınıflandırma

- SVM karar sınırı bu şekilde çözülür:

$$\min_{\theta} C \sum_{i=1}^m H_{y^i}(\theta^T \cdot x^i) + \frac{1}{2} \sum \theta_j^2,$$

$$H_y(z) = \begin{cases} 0, & y \cdot z \geq 1 \\ 1 - y \cdot z, & y \cdot z < 1 \end{cases}$$


$$y^i = \pm 1$$

SVM sınıflandırma

Fark edilecek önemli nokta:

- Eğer bütün örneklerde $y^i \cdot (\theta^T \cdot x^i) \geq 1$ *H-terimi sıfırdır*

$$\min_{\theta} C \sum_{i=1}^m H_{y^i}(\theta^T \cdot x^i) + \frac{1}{2} \sum \theta_j^2,$$


$$H_y(z) = \begin{cases} 0, & y \cdot z \geq 1 \\ 1 - y \cdot z, & y \cdot z < 1 \end{cases}$$



$$y^i = \pm 1$$

SVM sınıflandırma

Fark edilecek önemli nokta:

- Bu durumda sadece $\frac{1}{2} \sum \theta_j^2$ azaltmaya çalışıyoruz

$$\min_{\theta} \frac{1}{2} \sum \theta_j^2,$$


$$H_y(z) = \begin{cases} 0, & y \cdot z \geq 1 \\ 1 - y \cdot z, & y \cdot z < 1 \end{cases}$$


$$y^i = \pm 1$$

SVM sınıflandırma

SVM her zaman, mümkünse, pozitif örnekleri bir tarafa (“+1” üstüne) negatif örnekler diğer tarafa (“-1” altına) çekmeye çalışıyor

$$\min_{\theta} C \sum_{i=1}^m H_{y^i}(\theta^T \cdot x^i) + \frac{1}{2} \sum \theta_j^2,$$

$$H_y(z) = \begin{cases} 0, & y \cdot z \geq 1 \\ 1 - y \cdot z, & y \cdot z < 1 \end{cases}$$

$$y^i = \pm 1$$


SVM sınıflandırma

- Bütün pozitif örnekler “+1” üstüne ve negatif örnekler “-1” altına çekilebilirse, soruna “doğrusal olarak ayrılabilir bir sorun” diye diyoruz

SVM sınıflandırma

Doğrusal olarak ayrılabilir sorun

Positif örnekler: $y=1$



Negatif örnekler: $y=-1$

SVM sınıflandırma

- Doğrusal olarak ayrılabilir sorunlar için*, SVM'de karar sınırı uygun seçimle, H-terim sıfıra eşit yapılabilir ve sadece $\sum \theta_j^2$ teriminin azaltılması gerekiyor

$$\min_{\theta} C \sum_{i=1}^m H_{y^i}(\theta^T \cdot x^i) + \frac{1}{2} \sum \theta_j^2, \quad \text{min}$$

$$H_y(z) = \begin{cases} 0, & y \cdot z \geq 1 \\ 1 - y \cdot z, & y \cdot z < 1 \end{cases} \quad = 0$$

$$y^i = \pm 1$$

SVM sınıflandırma

- Aslında, en düşük $\sum \theta_j^2$ en büyük kenarlı doğrusal karar sınırı vermektedir (gösterilebilir, ama biz şimdi yapmayacağız)

SVM sınıflandırma

- Şu gösterilebilir ki, SVM problemin çözümü her zaman bu şekilde olmaktadır;

$$\theta_j = \sum \alpha^i \cdot y^i \cdot x_j^i$$

SVM sınıflandırma

- Doğrusal karar sınırının θ -parametresi, örneklerin **x-özellik-vektörlerinden** oluşturulur ... ama ...

$$\theta_j = \sum \alpha^i \cdot y^i \cdot x_j^i$$

- Bütün örnekler bu toplama girmez, genellikle sadece **birkaç alfa sıfırdan farklı** ve sadece o x-özellik-vektörler θ -parametresine girir
 - Tipik olarak, 1000 örneklerinden sadece 20-50 örnek θ -parametresine girebilir


SVM sınıflandırma

- Böyle katkıda olan orijinal örnekler “**destek vektörleri**” denir
- Sadece o örnekler θ -parametresini, ve bu anlamda SVM kararlarını, etkiliyor;
- Tüm diğer örnekler **karar verme için önemli değil** (SVM kararlarına etkilemez)

SVM sınıflandırma

Destek vektörleri:

Positif örnekler: $y=1$



Önemsiz örnekler; şunlar yoksa, karar sınırı değişmez

Önemli örnekler, bunlar karar sınırı belirtir; destek vektörleri bu

Negatif örnekler: $y=-1$



SVM sınıflandırma

“Destek vektör makineleri” bu nedenle diyoruz

SVM sınıflandırma


SVM optimizasyon sorununun 2. hali;

- Örnekler **doğrusal olarak ayrılmaz**
- Bu durumda, H-terim sıfıra konulmaz, ve SVM'de hem H-terimi hem de θ -terimi azaltılması lazım

$$\min_{\theta} C \sum_{i=1}^m H_{y^i}(\theta^T \cdot x^i) + \frac{1}{2} \sum \theta_j^2,$$

$$H_y(z) = \begin{cases} 0, & y \cdot z \geq 1 \\ 1 - y \cdot z, & y \cdot z < 1 \end{cases}$$

$$y^i = \pm 1$$



~~=0~~

SVM sınıflandırma

SVM optimizasyon sorununun 2. şekil;

- Bu durumda, C-sabiti önemli oluyor
- C-sabiti **yanlış örneklerin maliyetteki ağırlığını** belirtiyor

$$\min_{\theta} C \sum_{i=1}^m H_{y^i}(\theta^T \cdot x^i) + \frac{1}{2} \sum \theta_j^2,$$

$$H_y(z) = \begin{cases} 0, & y \cdot z \geq 1 \\ 1 - y \cdot z, & y \cdot z < 1 \end{cases}$$

$$y^i = \pm 1$$

önemli!

SVM sınıflandırma

- Büyük C için, SVM oldukça az yanlış karar yapmaya çalışacak
- Düşük C için, SVM daha çok yanlış karar yapılabilir ama oldukça büyük karar kenarı sağlamaya çalışacak

$$\min_{\theta} C \sum_{i=1}^m H_{y^i}(\theta^T \cdot x^i) + \frac{1}{2} \sum \theta_j^2,$$

$$H_y(z) = \begin{cases} 0, & y \cdot z \geq 1 \\ 1 - y \cdot z, & y \cdot z < 1 \end{cases}$$

$$\theta = \sum \alpha^i y^i x^i$$

SVM sınıflandırma

- SVM, kavramsal basit (yani, == en büyük karar kenarı) aynı zamanda **makine öğrenme en güçlü metodlarından biridir**
- *El yazısı karakter tanıma* (posta), *yüz tanıma* (facebook), *metin sınıflandırma* (haber seçme) uygulamalarında çok ileri yapay sınır ağları gibi yaklaşımlarla karşılaştırılabilir yada daha iyi perfomansı tipik olarak gösterir

SVM sınıflandırma

- Bu anda SVM yaklaşımı, makine öğrenme yaklaşımları olarak altın standart rolünde bulunmaktadır
- Daha ileri okuma için,
 - SVM, **Vladimir Vapnik** ve **Alexey Chernovenkis** tarafından **istatistiksel öğrenme teorisi** kullanarak türetilmiş
 - İstatistiksel öğrenme teorisi ve SVM ile ilgili İnternette birçok (ingilizce) kaynak var

SVM sınıflandırma


- SVM optimizasyon sorunu çözmek için, **dereceli azaltma** ve aşağıdaki **maliyet fonksiyonu** kullanılabilir

$$J(\theta) = C \sum_{i=1}^m H_{y^i}(\theta^T \cdot x^i) + \frac{1}{2} \sum \theta_j^2$$

Yakınsamaya kadar tekrarlayın {
bütün j 'ler için;

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

}



SVM sınıflandırma

- Daha verimli yöntemleri uygulanabilir
- SVM sorununun özel matematiksel yapısına sahip olması için, özel metodlar geliştirilmiş oldu

$$\min_{\theta} C \sum_{i=1}^m H_{y^i}(\theta^T \cdot x^i) + \frac{1}{2} \sum \theta_j^2,$$

$$H_y(z) = \begin{cases} 0, & y \cdot z \geq 1 \\ 1 - y \cdot z, & y \cdot z < 1 \end{cases}$$

$$\theta = \sum \alpha^i y^i x^i$$

SVM sınıflandırma

Bunların arasında;

- Sequential Minimal Optimization, SMO (**Ardışık minimal optimizasyon metodu**)
- Interior point convex optimization methods (**Konveks optimizasyonun iç nokta yöntemi**)

SVM sınıflandırma

SVM için **hazır yazılım paketleri** kullanılmalı;

- *SVM-light*
- *SVM-struct*
- *mySVM*
- *LIBSVM*

(www.support-vector-machines.org da daha çok yazılım paketleri bulunabilir)


SVM sınıflandırma

Lineer olmayan sınıflandırma için, lojistik regresyon gibi SVM, ek olan lineer olmayan karmaşık özellikler ile kullanılabilir

SVM sınıflandırma

Lineer olmayan ilişki:


kırmızı – $y=1$ örnekleri, mavi – $y=-1$ örnekleri



SVM sınıflandırma

Ek olan lineer olmayan yeni karmaşık özellik:


$$x' = g(x_1^2 + x_2^2)$$



SVM sınıflandırma

Bu özelliğe göre, muhtemelen lineer olmayan karar sınırı bu şekilde üretilebilir:

$$x' = x_1^2 + x_2^2 = 1$$



SVM sınıflandırma

- SVM’de, lineer olmayan özellikler için “**kernel**” (**çekirdek**) diye terim kullanılır, $K(x^i, x^j)$ sembol ile gösterilir
- Kerneller kullanarak, SVM lineer olmayan sınıflandırma için kullanılabilir

SVM sınıflandırma

- SVM problemi, bu şekilde de yazılabilir (**dual şekli** adlandırılan şekil);

$$\max \sum \alpha^i - \frac{1}{2} \sum \alpha^i \alpha^j y^i y^j (x^i \cdot x^j)$$

$$\sum \alpha^i y^i = 0$$

$$0 \leq \alpha^i \leq C$$

SVM sınıflandırma

- Bu SVM problemi, doğrudan α -parametreler (θ -parametreler değil) için yazılır (α , destek vektörlerinin ağırlıkları)

$$\max \sum \alpha^i - \frac{1}{2} \sum \alpha^i \alpha^j y^i y^j (x^i \cdot x^j)$$

$$\sum \alpha^i y^i = 0$$

$$0 \leq \alpha^i \leq C$$

$$\theta = \sum \alpha^i y^i x^i$$

SVM sınıflandırma

- Bu SVM probleminde, x 'ler bir skalar çarpım içinde girmektedir

$$\max \sum \alpha^i - \frac{1}{2} \sum \alpha^i \alpha^j y^i y^j (x^i \cdot x^j)$$

$$\sum \alpha^i y^i = 0$$

$$0 \leq \alpha^i \leq C$$


$$(x^i \cdot x^j) = \sum x_k^i x_k^j$$

SVM sınıflandırma

- Kernel şeklini sağlamak için, bu skalar çarpım lineer-olmayan bir şekile değiştirilir:

$$\max \sum \alpha^i - \frac{1}{2} \sum \alpha^i \alpha^j y^i y^j K(x^i, x^j)$$

$$\sum \alpha^i y^i = 0$$

$$0 \leq \alpha^i \leq C$$

Skalar çarpım yerine giriyor

$$(x^i \cdot x^j) \equiv K(x^i, x^j)$$

SVM sınıflandırma

- SVM kernel şekli olarak, en çok kullanılan Gauss (radyal) kerneli dir;

$$\max \sum \alpha^i - \frac{1}{2} \sum \alpha^i \alpha^j y^i y^j K(x^i, x^j)$$



$$K(x^i, x^j) = e^{-\frac{(x^i - x^j)^2}{2\sigma^2}}$$

SVM sınıflandırma

- Diğer popüler seçenekleri;

- Homojen polinom kerneli

$$K(x^i, x^j) = (x^i \cdot x^j)^d$$

- Homojen olmayan polinom kerneli

$$K(x^i, x^j) = (1 + x^i \cdot x^j)^d$$

- Hiperbolik tanjant kerneli

$$K(x^i, x^j) = \tanh(c + kx^i \cdot x^j)$$

SÜLEYMAN DEMİREL ÜNİVERSİTESİ



TEŞEKKÜRLER